ESCUELA POLITÉCNICA NACIONAL

Facultad de Ingeniería de Sistemas · Carrera de Ciencia de Datos e Inteligencia Artificial

INFORME DE PRÁCTICA N.º2

Diseño - Encuesta

Labo 2 del PEA · Asignatura IDSD422 — Estadística y Programación para Ciencia de Datos I

Estudiante(s)	Villacís Vega, Alejandro Xavier, Guido Fidel Quilumba Diaz, Jhon Jairo Tiupul Irua
Enfoque:	Compra en línea / app: experiencia.
Docente	Ing. Christian Suárez, M.Sc.
Período académico	2026-B
Fecha de entrega	28/10/2026
Repositorio (fork)	https://github.com/altas123linux/IDSD422-lab-muestreo-poblacion.git

1. Objetivo de la encuesta

Estimar el porcentaje Estimar el porcentaje de satisfacción con la compra en la app de RetailAndina mediante una encuesta aplicada en noviembre de 2026 a los clientes residentes en Quito que compraron en línea entre agosto y octubre de 2026, para decidir si el programa de fidelización se lanza en la aplicación.

Regla de decisión / Punto de partida: si al menos el 70 % de encuestados se encuentran satisfechos y al menos el 60 % probablemente usaría el programa, se recomienda lanzarlo primero en la aplicación.

2. Población objetivo

La población está estrictamente conformada por personas con 18 años o más que son residentes de la ciudad de Quito y que realizaron al menos una compra en línea en RetailAndina entre los meses de agosto y octubre del 2026.

Límites y justificación:

Se establece el límite de edad de 18 años o más, ya que a esa edad pueden dar su consentimiento informado y deciden sus compras por cuenta propia. Se considera que sean residentes de la ciudad de Quito, la decisión se toma para esta ciudad, ya que en otras ciudades las entregas, la cobertura y el stock pueden ser distintos. Además, facilita la recolección.

De la misma manera se considera a las personas que realizaron compras en línea entre agosto y octubre de 2026, porque estas personas pueden evaluar su experiencia de compra durante ese periodo. Esto permite obtener información sobre experiencias reales y facilita la recolección de datos mediante los contactos del equipo.

Quedan excluidos los menores de 18 años, personas que viven fuera de Quito, quienes solo compran en la tienda física o no compraron en línea en el periodo establecido, así como los integrantes del equipo y empleados, con el fin de evitar posibles conflictos de interés.

Al inicio de la encuesta se incluirá las siguientes preguntas filtro: ¿Tiene 18 años o más, genero, vive en Quito? Si la persona encuestada responde No, la encuesta termina.

3. Método de muestreo

- Método: El Muestreo aleatorio simple sobre el marco muestral, con análisis posterior por frecuencia de compra (clientes frecuentes vs. ocasionales).
- **Justificación:** El tamaño de muestra se calculó con la fórmula para proporciones $n = z^2 \cdot p(1 - p) / e^2$, usando el peor caso $p = 0,5$, un nivel de confianza del 95 % ($z = 1,96$) y un margen de error de ±10 %. El resultado es $n = 96$, que se redondea a 100. De ese total se obtendrán 30 respuestas reales, y el resto, hasta completar 100, se llenará con valores simulados. Con 100 respuestas el muestreo estratificado casi no mejoraría la precisión, por lo que su complejidad adicional no se justifica.

■ **Selección de los participantes:**

- El marco muestral está formado por los clientes de 18 años o más, residentes en Quito, que realizaron al menos una compra por la app de RetailAndina entre agosto y octubre de 2026. Se excluyen los empleados de RetailAndina y el equipo de BI.
- Cada cliente del marco tiene la misma probabilidad de ser elegido, así que no hay preferencia del investigador.
- La selección se hace con una sola extracción sobre toda la base, sin necesidad de definir estratos antes de contactar a nadie, lo que la hace simple de ejecutar y de reproducir.
- No se necesita información previa sobre cada cliente. La frecuencia de compra se pregunta en la pregunta 1 del cuestionario y después se usa para comparar grupos: ocasionales (1 a 3 compras) y frecuentes (4 o más compras).

■ **Implementación en código**

```
informes > pruebas_codigo > muestreo.py > ...
1   import pandas as pd
2
3   clientes = pd.read_csv("informes/pruebas_codigo/clientes_app.csv").drop_duplicates()  # marco
4
5   # Poblacion objetivo: 18+, Quito, compro por la app (ago-oct 2026), no empleados
6   poblacion = clientes[(clientes["edad"] >= 18) & (clientes["ciudad"] == "Quito")
7                        & (clientes["compro_app"]) & (~clientes["empleado"])].copy()
8
9   # Muestreo aleatorio simple: n = 96 redondeado a 100, con semilla para reproducibilidad
10  muestra = poblacion.sample(n=100, random_state=42)
11
12  print("Clientes en el marco:", len(clientes))
13  print("Clientes que cumplen la poblacion:", len(poblacion))
14  print("Tamaño de la muestra:", len(muestra))
15  print(muestra.head())
```

Salida de la implementación en Python

```
PS C:\Users\Lenovo LOQ\Desktop\Encuesta_RetailAndina> python informes/pruebas_codigo/muestreo.py
Clientes en el marco: 600
Clientes que cumplen la poblacion: 312
Tamaño de la muestra: 100
    id_cliente  edad ciudad  compro_app  empleado
457      C0458    64  Quito        True     False
21       C0022    33  Quito        True     False
122      C0123    41  Quito        True     False
129      C0130    41  Quito        True     False
54       C0055    63  Quito        True     False
PS C:\Users\Lenovo LOQ\Desktop\Encuesta_RetailAndina>
```

En la salida se observa que, de los 600 clientes del marco, 312 cumplen los criterios de la población objetivo, y de ellos se seleccionaron al azar los 100 que indica el tamaño de muestra calculado.

Este método resulta idóneo porque todos los clientes que cumplen los criterios tienen la misma probabilidad de ser seleccionados, sin que el investigador influya en quién entra a la muestra. Además, al no requerir información previa de los clientes, se puede aplicar con una sola extracción sobre toda la base, y la comparación entre clientes frecuentes y ocasionales sigue siendo posible gracias a la pregunta 1 del cuestionario.

4. Cuestionario (5–10 preguntas)

El formulario empieza con la pregunta filtro y con esta indicación: En esta encuesta, RetailAndina es la página web donde más compras por internet.

#	**Pregunta**	**Tipo de variable**	**Dtype al cargar**	**Opciones / escala**
1	Entre agosto y octubre de 2026, ¿cuántas compras hiciste en tu supermercado en línea?	Categórica ordinal	str (object)	1 compra, 2-3 compras, 4-6 compras, 7 o más compras
2	¿En qué rango de edad te encuentras?	Categórica ordinal	str (object)	18-29, 30-44, 45-59, 60 o más
3	¿Qué tan fácil o difícil te resultó encontrar los productos que buscabas en línea?	Categórica ordinal	int64	1 = Muy difícil, 2 = Difícil, 3 = Ni fácil ni difícil, 4 = Fácil, 5 = Muy fácil
4	En tu última compra en línea, ¿qué tan rápido o lento fue el proceso de pago?	Categórica ordinal	int64	1 = Muy lento, 2 = Lento, 3 = Normal, 4 = Rápido, 5 = Muy rápido
5	¿Cuánto tardó en llegar tu último pedido en línea, desde que lo pagaste?	Categórica ordinal	str (object)	Mismo día, 1-2 días, 3-5 días, Más de 5 días, Retiré en tienda

6	En general, ¿qué tan satisfecho o insatisfecho estás con tu experiencia de compra en línea?	Categórica ordinal	int64	1 = Muy insatisfecho, 2 = Insatisfecho, 3 = Neutral, 4 = Satisfecho, 5 = Muy satisfecho
7	¿Recomendarías comprar en RetailAndina en línea a un familiar o amigo?	Categórica binaria	str (object)	Si, No
8	Si se incluyera un programa de fidelización, ¿qué tan probable es que lo uses?	Cualitativa ordinal	int64	1=Nada probable · 2 Poco probable, 3=Ni probable ni improbable · 4 Probable · 5 Muy probable
9	¿Cuál de estos beneficios te motivaría más a usar un programa de fidelización?	Cualitativa nominal	Str(object)	Envío gratis / Descuentos exclusivos / Puntos acumulables / Entregas más rápidas / Otro

Columnas del CSV: respuesta_id (R001… reales, S001… simuladas), fecha (AAAA-MM-DD), frecuencia_compra, rango_edad, facilidad_busqueda, rapidez_pago, tiempo_entrega, monto_ultimo_pedido, satisfaccion_general, recomendaria, prob_uso_programa, beneficio_preferido y origen.

Nota: aunque las preguntas 3, 4, 6 y 8 lleguen como int64, se clasifican como ordinales: el dtype es solo una pista, no la clasificación. Si alguna quedara vacía, la columna pasaría a float64, por eso son obligatorias. El texto llega como str en pandas 3 (object en pandas 2), y el Si/No de la pregunta 7 también llega como texto, porque pandas solo convierte a bool los valores True/False. Las escalas tienen cinco puntos con ambos polos y un punto neutro, y nombran los dos extremos («fácil o difícil») para no inducir la respuesta; la pregunta 5 incluye «Retiré en tienda» para que las opciones sean exhaustivas.

5. Análisis de sesgos

Sesgo potencial	Mitigación
1. Sesgo de selección: la muestra real sale de los contactos del equipo, así que tiende a tener muchos jóvenes de 18 a 29 años, estudiantes y personas cómodas con la tecnología, que probablemente encuentran la app más fácil que un cliente de 50 años.	Declarar el método como conveniencia más referidos; repartir las invitaciones entre familiares de distintas edades; pedir referidos fuera del círculo cercano; revisar en la sección 7 la distribución de rango_edad y frecuencia_compra; presentar los resultados por grupo y como evidencia preliminar.
2. Sesgo de no respuesta: quienes tuvieron una mala experiencia o dejaron de comprar en línea tienen menos interés en contestar, y algunas personas no responden la encuesta. Por lo que no da datos generales.	Formulario corto (7 preguntas, unos 3 minutos) y anónimo; un solo recordatorio a las 24 horas; solo el monto es opcional; registrar las personas invitadas frente a las que respondieron para calcular la tasa de respuesta.
3. Sesgo de respuesta: al ser conocidos del equipo, los encuestados pueden dar calificaciones altas para ayuda o para no quedar mal.	Formulario anónimo (sin correo ni nombre), el encuestador no está presente al responder, preguntas neutras con punto medio y aviso de que no hay respuestas correctas y de que las críticas son igual de útiles.

6. Confidencialidad (RA3)

Datos personales que se solicitan: Se solicita únicamente el rango de edad para conocer la participación de los diferentes grupos de edad en la encuesta. El monto del último pedido es opcional y aproximado. No se solicitan nombres, cédula, correo electrónico, teléfono ni dirección, porque estos datos no son necesarios para el objetivo del estudio y podrían permitir la identificación de los participantes.

Plan de anonimización: El formulario de Google se configura para no recopilar correos electrónicos. Al exportar las respuestas, se elimina la marca temporal y se conserva únicamente la fecha de respuesta. Los datos se organizan sin nombres ni información que permita identificar directamente a los participantes. Las listas de contactos invitados permanecen con cada integrante del equipo y no se incluyen en el repositorio del proyecto.

El archivo CSV original con las respuestas no se sube al repositorio. Para evitarlo, el archivo .gitignore excluye los archivos que contienen respuestas reales. Únicamente se publica el archivo plantillas/encuesta_respuestas.csv con los datos anonimizados y la columna origen. Finalmente, en el informe no se presentan cruces de datos que incluyan menos de tres personas, con el fin de reducir el riesgo de identificar a los participantes.

7. Verificación con herramientas (Python/R)

El script de verificación scripts/verificacion_encuesta.py lee el archivo plantillas/ encuesta_respuestas.csv, reporta únicamente una simulación a los dtypes para esta platilla, ya que aun no se tiene registrado oficialmente las encuestas reales para este enfoque, por eso se habla de que aún falta completar información para este punto. De modo que, conforme se desarrolle el laboratorio se mostrará en los futuros informes los datos correspondientes.

